深度学习

PaddlePaddle基础

DAY06

PaddlePaddle概述

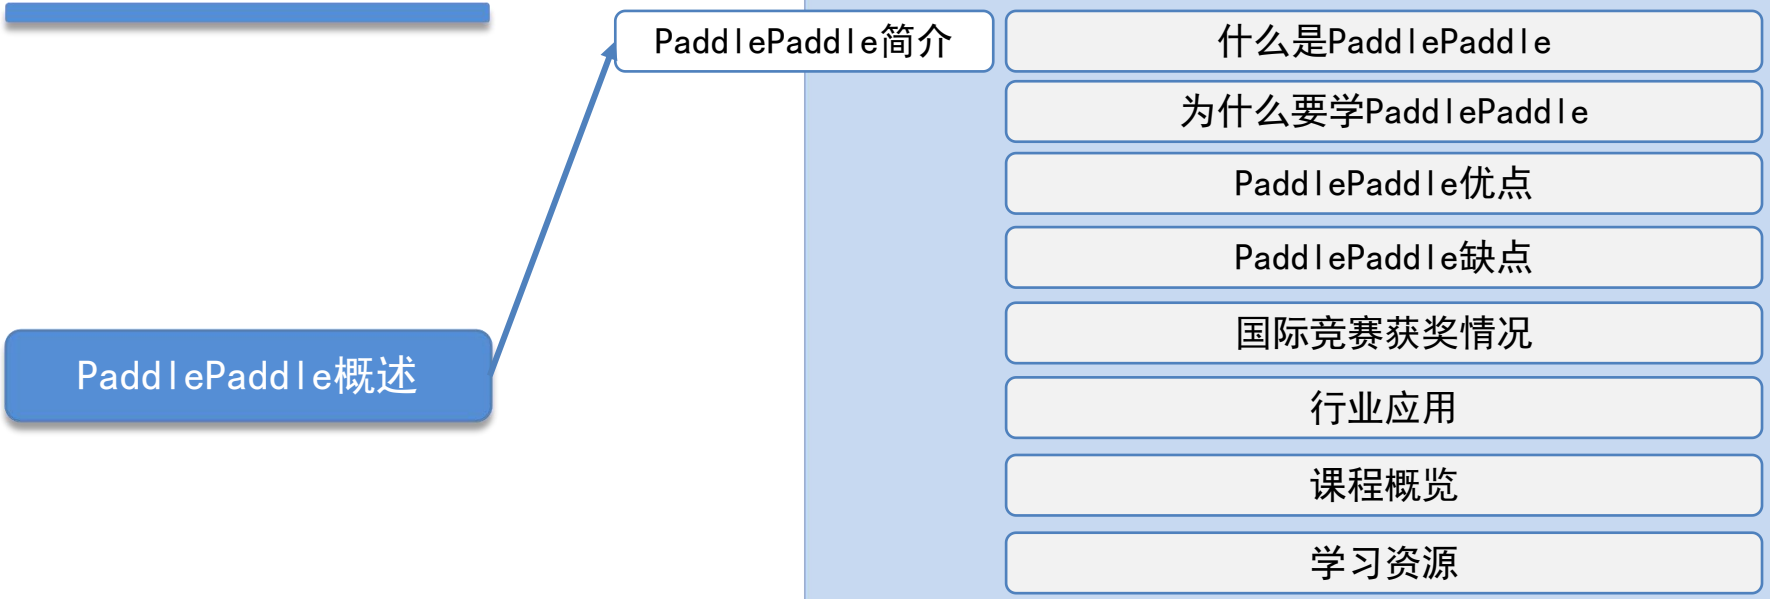

PaddlePaddle简介

什么是PaddlePaddle

- PaddlePaddle（Parallel Distributed Deep Learning，中文名飞桨）是百度公司推出的开源、易学习、易使用的分布式深度学习平台
- 源于产业实践，在实际中有着优异表现
- 支持多种机器学习经典模型

知识讲解

为什么学习PaddlePaddle

- 开源、国产
- 能更好、更快解工程决实际问题

知识讲解

PaddlePaddle优点

知识讲解

- 易用性。语法简洁，API的设计干净清晰
- 丰富的模型库。借助于其丰富的模型库，可以非常容易的复现一些经典方法
- 全中文说明文档。首家完整支持中文文档的深度学习平台
- 运行速度快。充分利用 GPU 集群的性能，为分布式环境的并行计算进行加速

PaddlePaddle缺点

- 教材少
- 学习难度大、曲线陡峭

知识讲解

国际竞赛获奖情况

知识讲解

获奖模型/模块		国际竞赛	
视觉领域	PyramidBox模型	WIDER FACE三项测试子集	第一
	Attention Clusters网络模型	ActivityNet Kinetics Challenge 2017	第一
	StNet模型	ActivityNet Kinetics Challenge 2018	第一
	基于Faster R-CNN的多模型	Google AI Open Images-Object Detection Track	第一
增强学习框架PARL		NIPS AI for Prosthetics Challenge	第一

行业应用

知识讲解

农业

智能桃子分拣机
节约 90% 人力成本

林业

病虫害监测
识别准确率达到 90%

工业

公共场所控烟

零售

商品销量预测
单店生鲜报损降低 30%

人力

AI建立匹配系统
5倍面邀成功率

制造

智能零件分拣
人工效率增加 1 倍

石油

地震波藏油预测

通讯

基站网络故障预警

地产

智能楼宇管理
制冷系统节电 20%

汽车

充电桩故障预警
准确达 90%

学习资源

知识讲解

- **官网**
  - ✓ 地址：https://www.paddlepaddle.org.cn/
  - ✓ 内容：学习指南、文档、API手册
- **百度云智学院**
  - ✓ 地址：http://abcxueyuan.cloud.baidu.com/#/courseDetail?id=14958
  - ✓ 内容：教学视频
- **AIStudio**
  - ✓ 地址：https://aistudio.baidu.com/aistudio/projectoverview/public/1
  - ✓ 内容：项目案例

体系结构

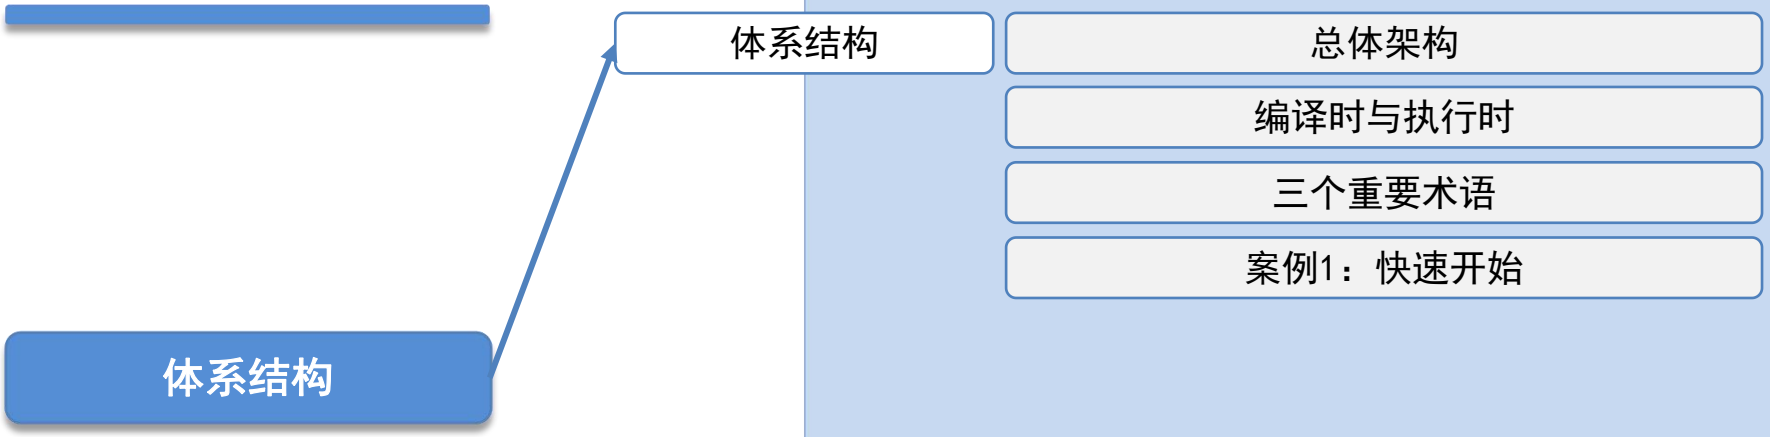

体系结构

总体架构

知识讲解

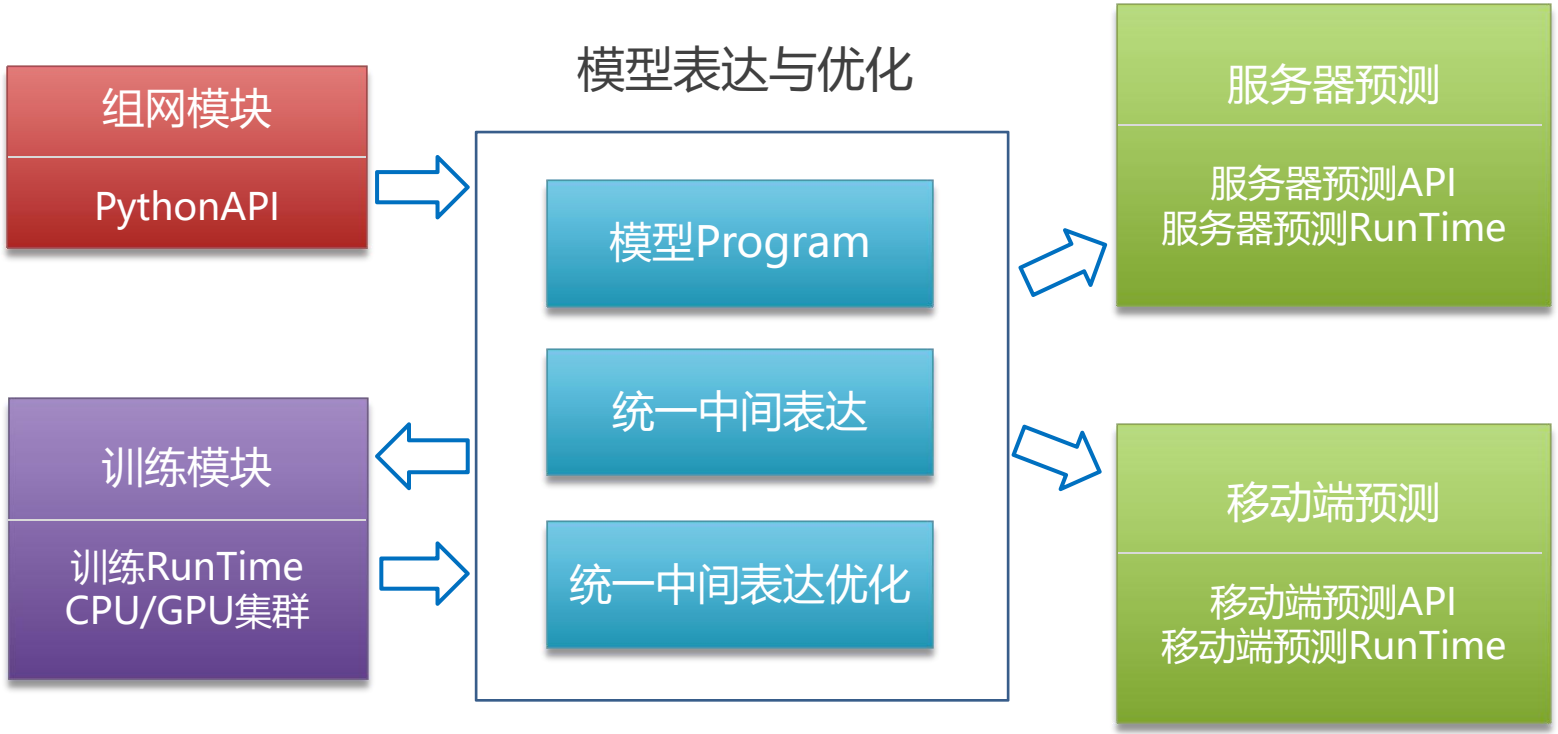
组网模块
PythonAPI
模型表达与优化
模型Program
统一中间表达
统一中间表达优化
训练模块
训练RunTime
CPU/GPU集群
服务器预测
服务器预测API
服务器预测RunTime
移动端预测
移动端预测API
移动端预测RunTime

编译与执行过程

知识讲解

1. 用户编写的python程序通过调用 Paddle 提供的算子，向Program 中添加变量（ Tensor ）以及对变量的操作（ Operators 或者 Layers ）
2. 原始Program在框架内部转换为中间描述语言： ProgramDesc
3. Transpiler 接受一段 ProgramDesc ，输出一段变化后的 ProgramDesc ，作为后端 Executor 最终需要执行的 Program
4. 执行 ProgramDesc 中定义的 Operator（可以类比为程序语言中的指令），在执行过程中会为 Operator 创建所需的输入输出并进行管理

编译与执行过程（续）

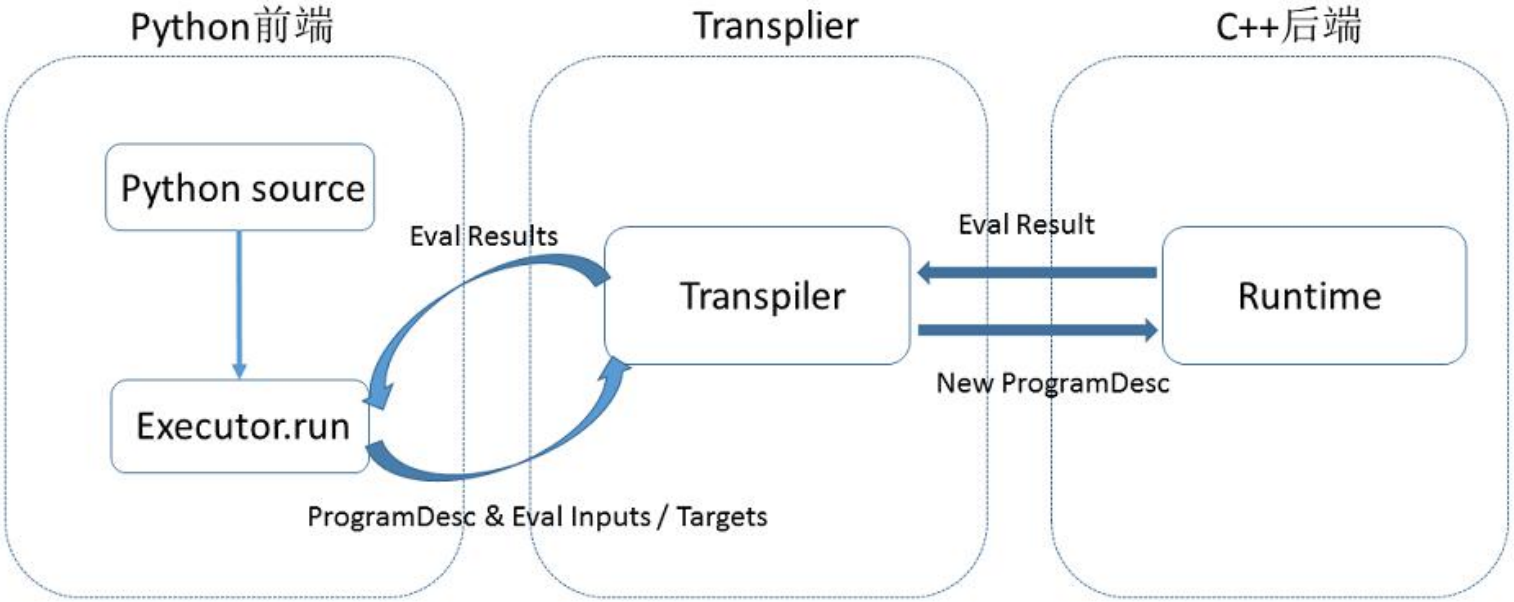

知识讲解

三个重要术语

- Fluid：定义程序执行流程
- Program：对用户来说一个完整的程序
- Executor：执行器，执行程序

知识讲解

案例1：快速开始

课堂练习

```
import paddle.fluid as fluid

# 创建两个类型为int64，形状为1行1列的张量
x = fluid.layers.fill_constant(shape=[1], dtype="int64", value=5)
y = fluid.layers.fill_constant(shape=[1], dtype="int64", value=1)
z = x + y
# print(z) # z为对象，此时还没有值

# 创建Executor执行器
place = fluid.CPUPlace()  # 指定在CPU上运行
exe = fluid.Executor(place)  # 创建执行器

result = exe.run(fluid.default_main_program(), fetch_list=[z])
print(result[0][0])  # result为1*1的张量
```

基本概念与操作

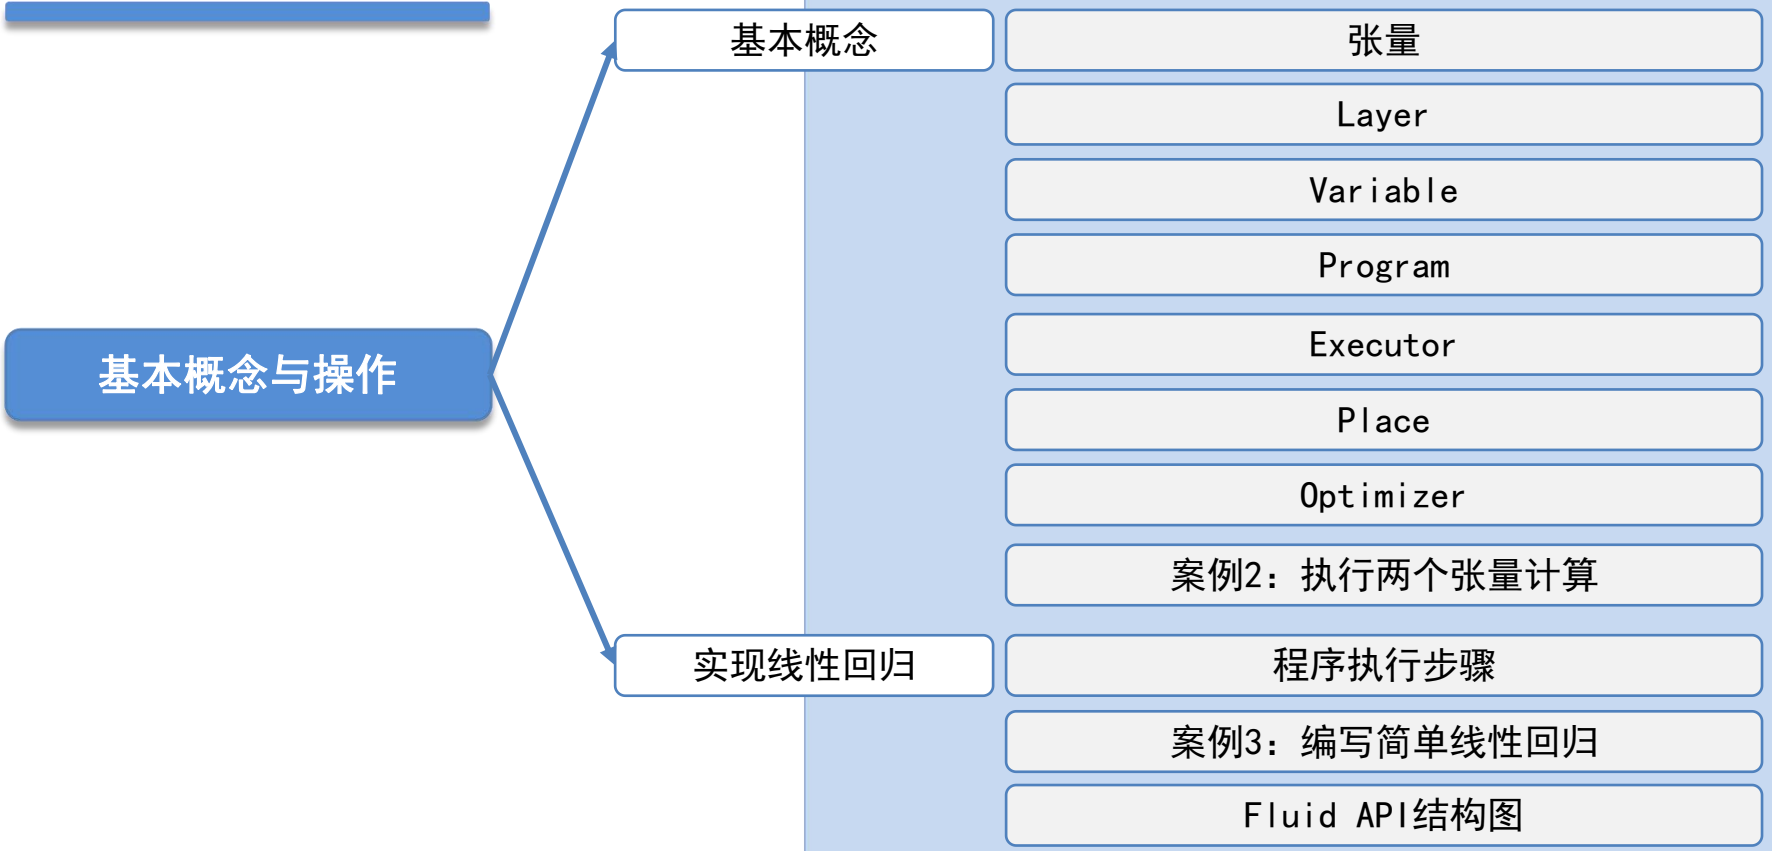
基本概念与操作
基本概念
张量
Layer
Variable
Program
Executor
Place
Optimizer
案例2：执行两个张量计算
实现线性回归
程序执行步骤
案例3：编写简单线性回归
Fluid API结构图

基本概念

张量

- 什么是张量

  张量（Tensor）：多维数组或向量，同其它主流深度学习框架一样，PaddlePaddle使用张量来承载数据

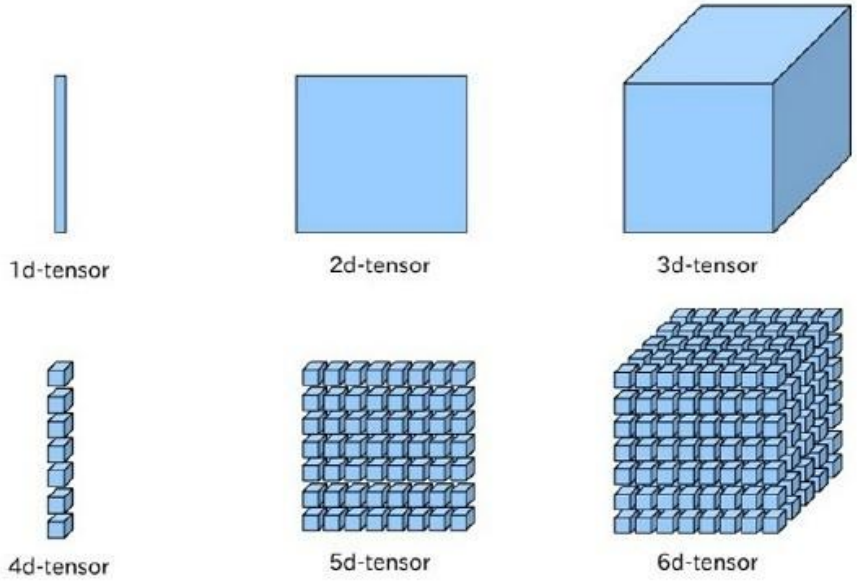

知识讲解

张量（续1）

- 张量示例

  灰度图像为二维张量（矩阵），彩色图像为三维张量

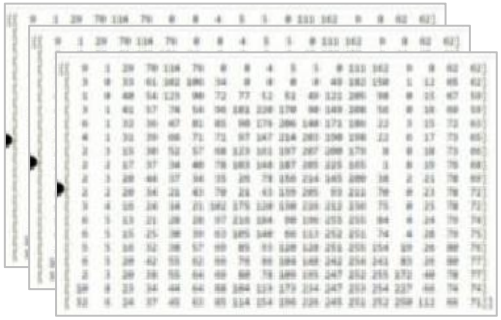

知识讲解

LoDTensor

- LoD(Level-of-Detail) Tensor是Paddle的高级特性，是对Tensor的一种扩充。LoDTensor通过牺牲灵活性来提升训练的效率。
- LoDTensor用来处理变长数据信息，将长度不一致的维度拼接为一个大的维度，并引入了一个索引数据结构（LoD）来将张量分割成序列。

知识讲解

LoDTensor（续）

知识讲解

- 假设一个mini-batch中有3个句子，每个句子中分别包含3个、1个和2个单词，我们可以用(3+1+2)xD维Tensor 加上一些索引信息来表示这个mini-batch：

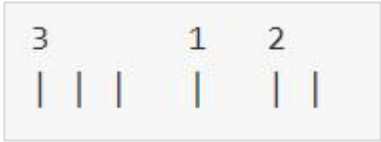

- 假设存在一个mini-batch中包含3个句子、1个句子和2个句子的文章，每个句子都由不同数量的单词组成，则这个mini-batch的可以表示为2-Level的LoDTensor：

Layer

- 表示一个独立的计算逻辑，通常包含一个或多个operator（操作），如layers.relu表示ReLU计算；layers.pool2d表示pool操作。Layer的输入和输出为Variable。

知识讲解

Variable

- 表示一个变量，在paddle中，Variable 基本等价于 Tensor 。Variable进入Layer计算，然后Layer返回Variable。创建变量方式：

知识讲解

```
x = fluid.layers.data(name="x", shape=[1], dtype="float32")
y = fluid.layers.data(name="y", shape=[1], dtype="float32")
```

Python变量

Paddle变量

Variable（续）

知识讲解

- Paddle 中存在三种 Variable：
  - ✓ **模型中的可学习参数：**包括网络权重、偏置，生存期和整个训练任务一样长。通过 fluid.layers.create_parameter 来创建可学习参数
  - ✓ **占位 Variable：**Paddle 中使用 fluid.data 来接收输入数据，fluid.data 需要提供输入 Tensor 的形状信息，当遇到无法确定的维度时，相应维度指定为 None
  - ✓ **常量 Variable：**通过 fluid.layers.fill_constant 来实现常量Variable

Program

- Program包含Variable定义的多个变量和Layer定义的多个计算，是一套完整的计算逻辑。从用户角度来看，Program是顺序、完整执行的。**program 的作用是存储网络结构，但不存储参数。**

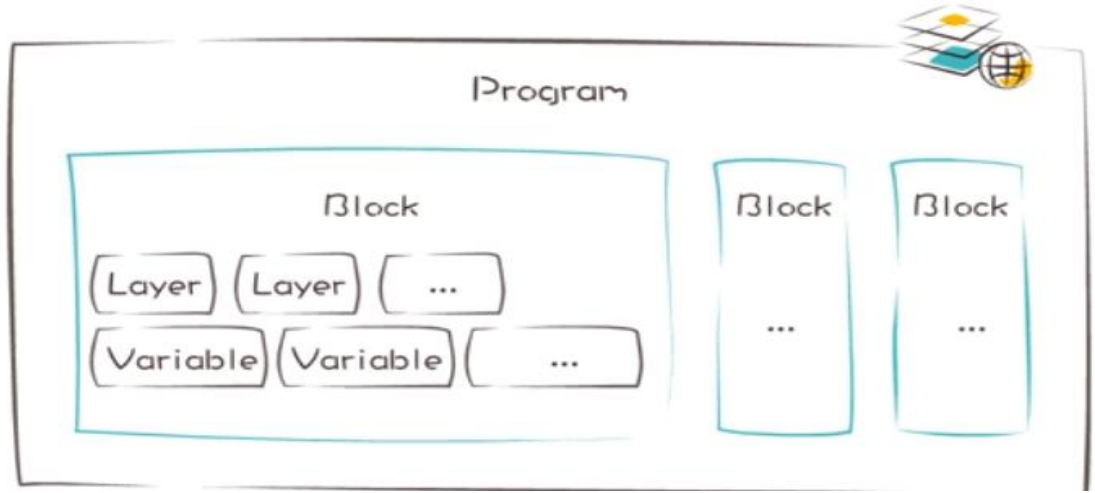

知识讲解

Program（续）

- 用户完成网络定义后，一段 Paddle 程序中通常存在 2 个 Program
  - ✓ **fluid.default_startup_program**：定义了模型参数初始化、优化器参数初始化、reader初始化等各种操作。该program可以由框架自动生成，使用时无需显式地创建
  - ✓ **fluid.default_main_program** ：定义了神经网络模型，前向反向计算，以及模型参数更新、优化器参数更新等各种操作

知识讲解

Scope

知识讲解

- scope 在 paddle 里可以看作变量空间，存储fluid创建的变量。变量存储于unordered_map 数据结构中，该结构类似于python中的dict，键是变量的名字，值是变量的指针。
- 一个paddle程序有一个默认的全局scope（可以通过fluid.global_scope() 获取）。如果没有主动创建 scope 并且通过 fluid.scope_guard() 替换当前 scope，那么所有参数都在全局 scope 中。**参数创建的时机不是在组网时，而是在 executor.run() 执行时。**
- program 和 scope 配合，才能表达完整模型（模型=网络结构+参数）

Executor

- Executor用来接收并执行Program，会一次执行Program中定义的所有计算。通过feed来传入参数，通过fetch_list来获取执行结果。

```
outs = exe.run(fluid.default_main_program(), # 默认程序上执行
               feed=params, # 喂入参数
               fetch_list=[result]) # 获取结果
```

知识讲解

Place

- PaddlePaddle可以运行在Intel CPU，Nvidia GPU，ARM CPU和更多嵌入式设备上，可以通过Place用来指定执行的设备（CPU或GPU）。

```
place = fluid.CPUPlace()  # 指定CPU执行
place = fluid.CUDAPlace(0)# 指定GPU执行
```

知识讲解

Optimizer

- 优化器，用于优化网络，一般用来对损失函数做梯度下降优化，从而求得最小损失值

知识讲解

案例2：执行两个张量计算

课堂练习

```
import paddle.fluid as fluid
import numpy

# 创建x, y两个2行3列，类型为float32的变量(张量)
x = fluid.layers.data(name="x", shape=[2, 3], dtype="float32")
y = fluid.layers.data(name="y", shape=[2, 3], dtype="float32")
x_add_y = fluid.layers.elementwise_add(x, y)  # 两个张量按元素相加
x_mul_y = fluid.layers.elementwise_mul(x, y)  # 两个张量按元素相乘

place = fluid.CPUPlace()  # 指定在CPU上执行
exe = fluid.Executor(place)  # 创建执行器
exe.run(fluid.default_startup_program())  # 初始化网络

a = numpy.array([[1, 2, 3],
                 [4, 5, 6]])  # 输入x，并转换为数组
b = numpy.array([[1, 1, 1],
                 [2, 2, 2]])  # 输入y，并转换为数组
params = {"x": a, "y": b}
outs = exe.run(fluid.default_main_program(),  # 默认程序上执行
               feed=params,  # 喂入参数
               fetch_list=[x_add_y, x_mul_y])  # 获取结果
for i in outs:
    print(i)
```

程序执行步骤

知识讲解

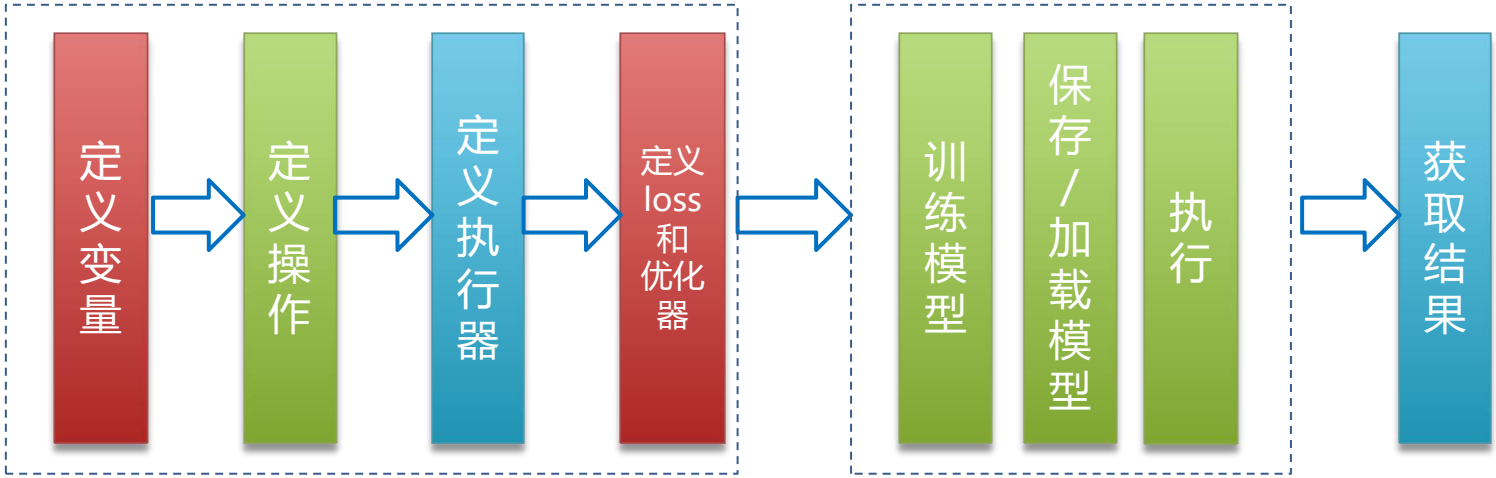

案例3：编写简单线性回归

课堂练习

- 任务：
  - ✓ 给出输入样本
  - ✓ 给出实际输出样本
  - ✓ 找出 $y = wx+b$ 公式中的 w 和 b

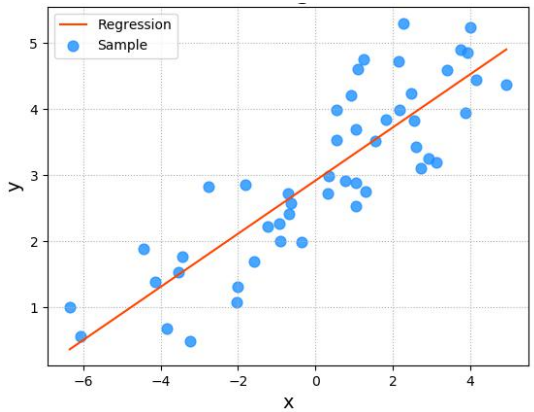

- 思路：
  - ✓ 定义输入数据、实际输出结果
  - ✓ 将数据送入神经网络进行训练（全连接网络，即分类器）
  - ✓ 根据实际输出、预测输出之间的损失值，进行梯度下降，直到收敛到极小值为止

案例3：编写简单线性回归（续）

- 技术要点：
  - ✓ 神经网络，选择 *fluid.layers.fc( )*，该函数在神经网络中建立一个全连接层。接收多个输入，为每个输入分配一个权重w, 并维护一个偏置值b；预测时产生一个输出
  - ✓ 损失函数：回归问题，选择均方差 *fluid.layers.*square_error_cost和 *fluid.layers.mean( )*作为损失函数
  - ✓ 优化器：随机梯度下降优化器 *fluild.SGD*，做梯度下降计算

代码见：simple_lr.py

课堂练习

fluid API结构图

知识讲解

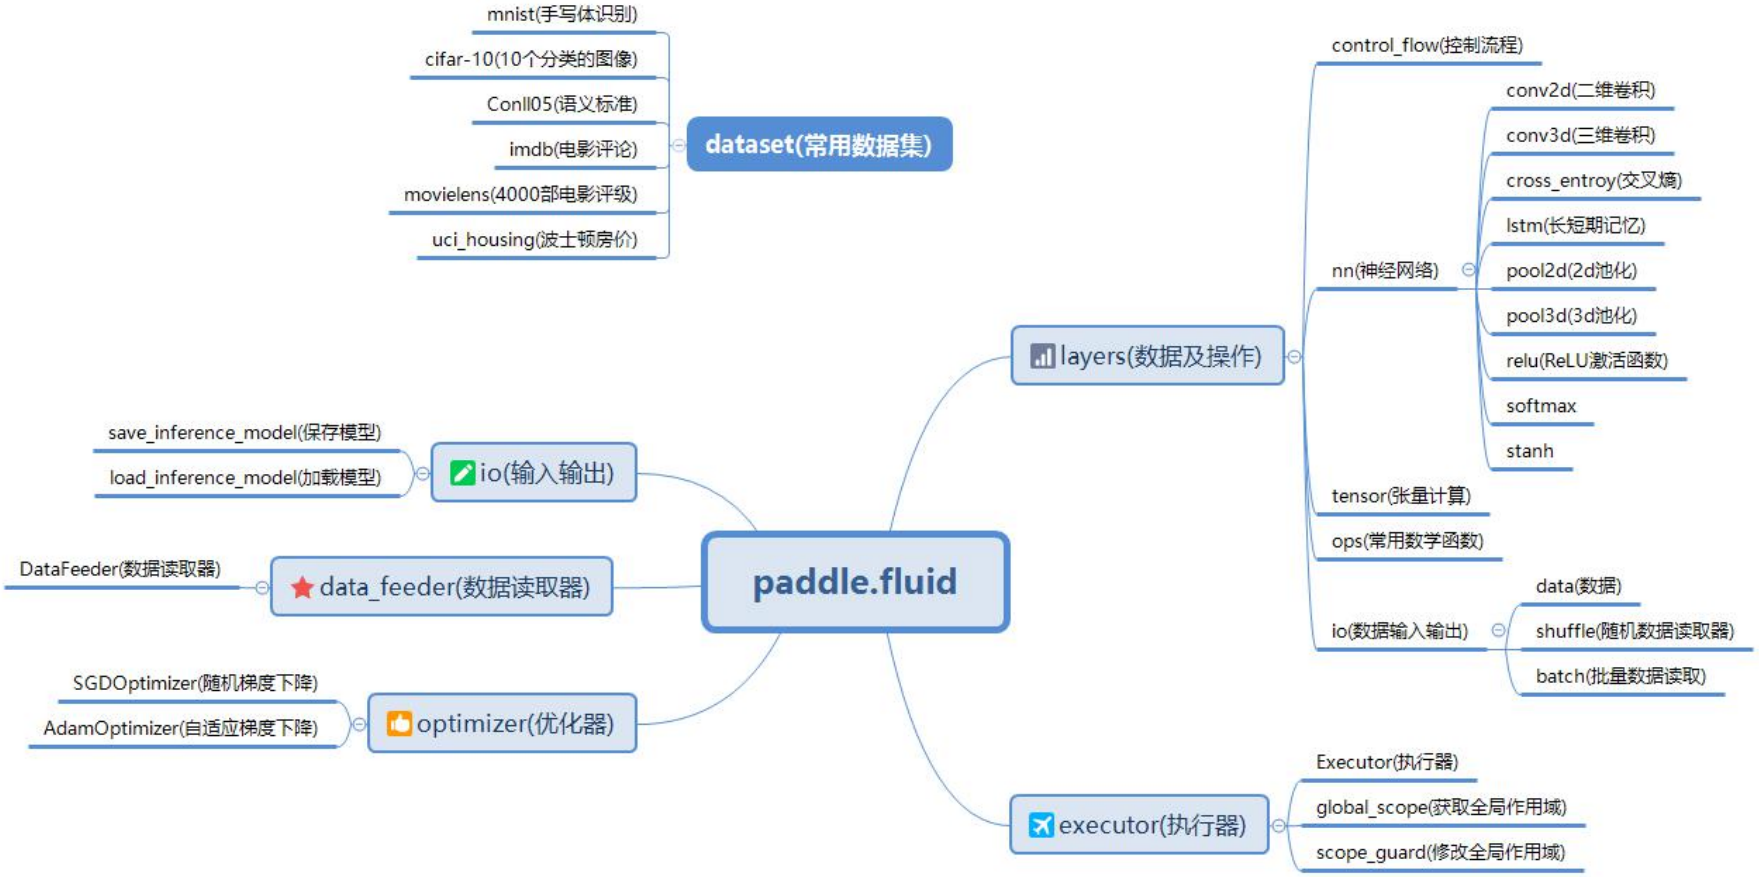

数据准备

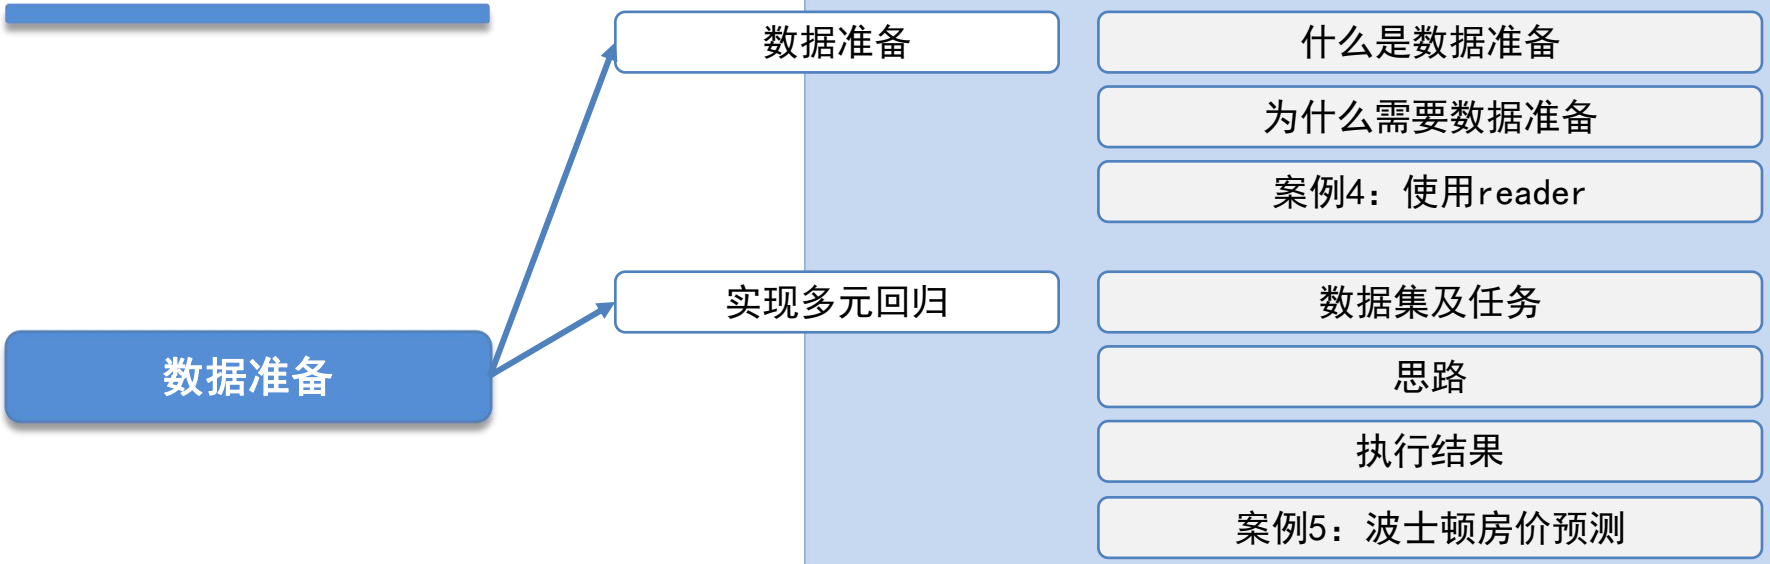
数据准备
数据准备
什么是数据准备
为什么需要数据准备
案例4：使用reader
实现多元回归
数据集及任务
思路
执行结果
案例5：波士顿房价预测

数据准备

深度学习数据读取要求

知识讲解

- **从文件读入数据。**因为程序无法保存大量数据，数据一般保存到文件中，所以需要单独的数据读取操作
- **批量快速读入。**深度学习样本数据量较大，需要快速、高效读取（批量读取模式）
- **随机读入。**为了提高模型泛化能力，有时需要随机读取数据（随机读取模式）

案例4：使用reader

- 自定义reader creator，从文本文件test.txt中读取一行数据

```
import numpy
import paddle

def reader_creator(file_path):
    def reader():
        with open(file_path, "r") as f:
            lines = f.readlines()
            for line in lines:
                yield line
    return reader

reader = reader_creator("test.txt")
for data in reader():
    print(data, end="")
```

课堂练习

案例4：使用reader（续1）

- 从上一个reader中以随机方式读取数据

```
1   import numpy
2   import paddle
3
4   def reader_creator(file_path):
5       def reader():
6           with open(file_path, "r") as f:
7               lines = f.readlines()
8               for line in lines:
9                   yield line
10      return reader
11
12  reader = reader_creator("test.txt")
13  shuffle_reader = paddle.reader.shuffle(reader, 10)
14  for data in shuffle_reader():
15      print(data, end="")
```

课堂练习

案例4：使用reader（续2）

- 从上一个随机读取器中，分批次读取数据

```
1   import numpy
2   import paddle
3
4   def reader_creator(file_path):
5       def reader():
6           with open(file_path, "r") as f:
7               lines = f.readlines()
8               for line in lines:
9                   yield line
10      return reader
11
12  reader = reader_creator("test.txt")
13  shuffle_reader = paddle.reader.shuffle(reader, 10)
14  batch_reader = paddle.batch(shuffle_reader, 3)
15  for data in batch_reader():
16      print(data, end="")
```

课堂练习

实现多元回归

数据集及任务

知识讲解

- 数据集介绍
  - ✓ 数据量：506笔
  - ✓ 特征数量：13个（见右图）
  - ✓ 标签：价格中位数
- 任务：根据样本数据，预测房价中位数（回归问题）

属性名	解释	类型
CRIM	该镇的人均犯罪率	连续值
ZN	占地面积超过25.000平方呎的住宅用地比例	连续值
INDUS	非零售商业用地比例	连续值
CHAS	是否邻近Charies River	离散值，1=邻近；0=不邻近
NOX	一氧化氮浓度	连续值
RM	每栋房屋的平均客房数	连续值
AGE	1940年之前建成的自用单位比例	连续值
DIS	到波士顿5个就业中心的加权距离	连续值
RAD	到径向公路的可达性指数	连续值
TAX	全值财产税率	连续值
PTRATIO	学生与教师的比例	连续值
B	1000(BK-0.63)^2	连续值
LSTAT	低收入人群占比	连续值
MEDV	同类房屋价格的中位数	连续值

思路

知识讲解

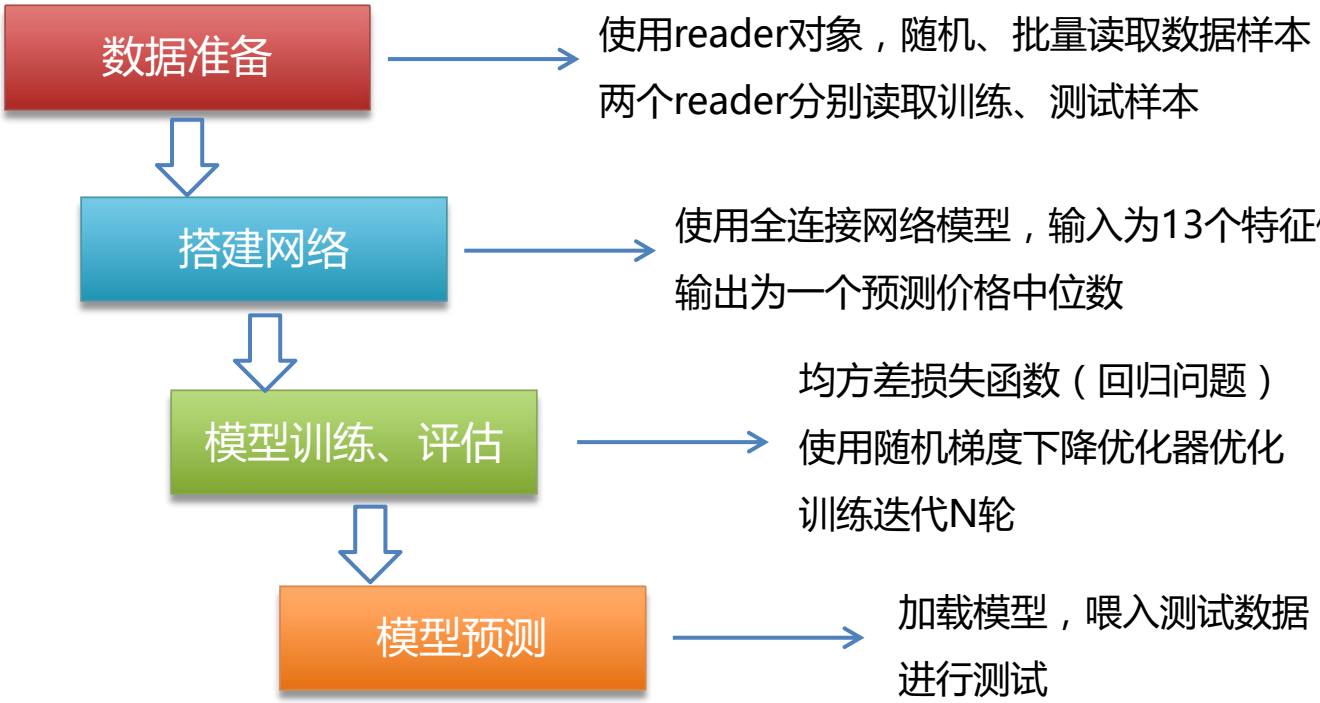

代码见：linear_regression.py

执行结果

知识讲解

损失函数收敛过程

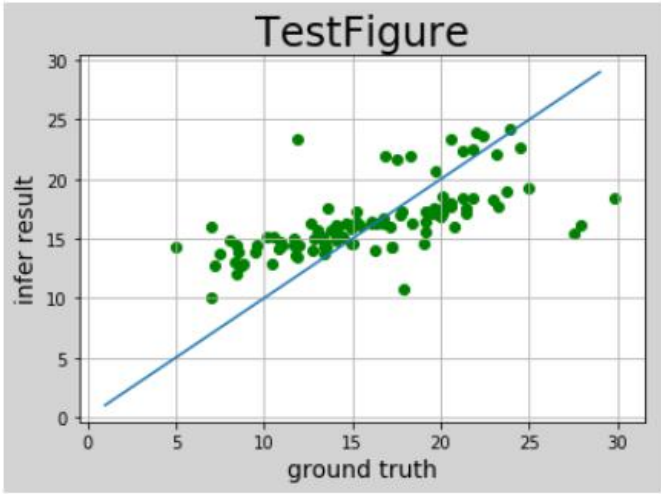

预测值与实际值对比

案例5：波士顿房价预测

- 全部代码见：uci_housing.py

课堂练习

今日总结

- PaddlePaddle体系结构与基本概念
  - Tensor, Layer, Program, Variable, Executor,Place
  - Fluid API组织结构
- 案例：
  - 简单线性回归
  - 机器学习经典案例：波士顿房价预测